TRATADO ACADÊMICO DE ESTATÍSTICA

Notas de Inferência Estatística Bayesiana

Luca Ferreira Barboza

Uma Abordagem Epistêmica, Analítica e Computacional

Módulo 1 Fundamentos e Modelos de Probabilidade

> 💡 **Sinopse Conceitual**
>
> A inferência estatística dedica-se a responder: *o que podemos aprender sobre o mundo a partir de observações empíricas incompletas?* O paradigma bayesiano estabelece que qualquer quantidade desconhecida — sejam parâmetros latentes θ, estados não observados da natureza ou previsões futuras — deve ser tratada como uma variável aleatória governada pelas leis da probabilidade. Os modelos probabilísticos discretos e contínuos funcionam como as lentes que traduzem tanto o processo gerador de dados (a verossimilhança $p(x \mid \theta)$) quanto o conhecimento inicial acumulado antes da coleta da amostra.

1.1 Paradigma Bayesiano versus Paradigma Frequentista

A grande bifurcação da inferência estatística não reside em desacordos de cálculo, mas sim na **concepção epistemológica da incerteza e da probabilidade.** Compreender essa distinção é indispensável para evitar equívocos graves de interpretação em testes e intervalos.

Critério	Abordagem Frequentista (Clássica)	Abordagem Bayesiana
Conceito de Probabilidade	Frequência relativa de ocorrência de um evento em um número infinito de repetições hipotéticas e idênticas do experimento.	Grau de crença racional ou estado epistêmico de incerteza do pesquisador, condicionado à informação disponível.
Natureza do Parâmetro θ	Uma **constante fixa desconhecida** no universo. Faz sentido dizer que $\theta = 0.5$, mas não que $P(\theta > 0.5) = 0.8$.	Uma **variável aleatória** dotada de uma distribuição de probabilidade que quantifica nossa incerteza sobre ele.
Papel dos Dados x	Uma realização entre infinitos pontos amostrais possíveis no espaço amostral Ω.	A **única evidência física real e concreta** observada (x_{obs}). Toda a

Critério	Abordagem Frequentista (Clássica)	Abordagem Bayesiana
	Avaliam-se procedimentos baseando-se no comportamento médio em repetições.	inferência deve condicionar estritamente aos dados reais.
Uso de Contrafactuais	Sim. Métricas como o p-valor integram probabilidades de dados que *jamais ocorreram* mas que seriam "mais extremos que o observado".	Não. Uma vez realizada a amostra, resultados alternativos que poderiam ter ocorrido em universos paralelos são irrelevantes.
Incorporação de Conhecimento Prévio	Indireta ou informal (via desenho amostral ou restrições ad-hoc de parâmetros).	Formal e axiomática: através da **distribuição a priori** $p(\theta)$ integrada via Teorema de Bayes.
Interpretação do Intervalo	*"Se repetirmos este ensaio 100 vezes, 95% dos intervalos construídos conterão o verdadeiro parâmetro fixo."* (O parâmetro não tem probabilidade de estar lá).	*"A probabilidade a posteriori de que o parâmetro θ pertença ao intervalo $[a, b]$, dado os dados observados, é de 95%."*

> ⚠️ **A Falácia da Transposição do Condicional**
>
> Na inferência clássica, o valor-p calcula a probabilidade dos dados sob a hipótese nula: $P(\text{Dados tão ou mais extremos} \mid H_0)$. No entanto, a pergunta genuína que qualquer cientista faz é exatamente a inversa: *"Dada a evidência observada, qual a probabilidade de a hipótese ser verdadeira?"*, ou seja, $P(H_0 \mid \text{Dados})$. Inverter essas probabilidades sem considerar a probabilidade a priori de H_0 é um erro probabilístico análogo a confundir $P(\text{febre} \mid \text{gripe})$ com $P(\text{gripe} \mid \text{febre})$.

1.2 Princípio da Verossimilhança e Suficiência

A Função de Verossimilhança

Dado um modelo probabilístico $p(x \mid \theta)$, a **função de verossimilhança** $l(\theta; x)$ representa a densidade conjunta ou probabilidade avaliada no ponto amostral observado x, considerada estritamente como função do parâmetro desconhecido $heta$:

$$l(\theta; x) = p(x \mid \theta), \quad \theta \in \Theta$$

É vital lembrar que $l(\theta; x)$ **não é uma densidade de probabilidade em** θ. Em geral, a integral de $l(\theta; x)$ em relação a θ não é igual a 1 (e pode até ser infinita). A verossimilhança apenas estabelece uma plausibilidade relativa: se $l(\theta_1; x) > l(\theta_2; x)$, os dados observados tornam o parâmetro θ_1 mais plausível que θ_2.

> 📘 **Princípio da Verossimilhança (Likelihood Principle)**
>
> Se dois experimentos independentes envolvendo o mesmo parâmetro de interesse θ geram funções de verossimilhança que são proporcionais para os dados efetivamente coletados, isto é:
>
> $$l_1(\theta; x_1) = c(x_1, x_2)\, l_2(\theta; x_2) \quad \forall\, \theta \in \Theta$$
>
> onde a constante $c(x_1, x_2) > 0$ não depende de θ, então **toda e qualquer conclusão inferencial sobre** θ **deve ser estritamente idêntica** nos dois experimentos.

A Regra de Parada (Stopping Rule Principle)

Uma consequência notável do Princípio da Verossimilhança é que a **intenção do experimentador ao coletar os dados não deve alterar a inferência.** Considere o exemplo clássico:

- **Pesquisador A (Modelo Binomial):** Decide de antemão lançar uma moeda $n = 12$ vezes. Observa $x = 3$ caras e 9 coroas.

$$p_A(x = 3 \mid \theta) = \binom{12}{3} \theta^3 (1-\theta)^9 = 220\, \theta^3 (1-\theta)^9$$

- **Pesquisador B (Modelo Binomial Negativo):** Decide lançar a moeda até obter $r = 3$ caras. Acontece que a 3ª cara surgiu exatamente no 12º lançamento ($y = 9$ coroas antes da 3ª cara):

$$p_B(y = 9 \mid \theta) = \binom{9+3-1}{3-1} \theta^3 (1-\theta)^9 = \binom{11}{2} \theta^3 (1-\theta)^9 = 55\, \theta^3 (1-\theta)^9$$

Note que as duas verossimilhanças são proporcionais:

$$l_A(\theta) = \frac{220}{55} l_B(\theta) = 4\, l_B(\theta) \propto \theta^3 (1-\theta)^9$$

Para o estatístico bayesiano, o Teorema de Bayes cancela o fator multiplicativo 4 na constante de normalização, resultando em **distribuições a posteriori absolutamente idênticas.** Para o estatístico frequentista, contudo, o cálculo do valor-p para a hipótese $H_0 : \theta = 0.5$ envolve somar caudas de distribuições diferentes, gerando p-valores distintos ($p \approx 0.073$ para a Binomial e $p \approx 0.032$ para a Binomial Negativa), o que levaria a conclusões científicas opostas para o mesmíssimo conjunto de dados!

Estatísticas Suficientes e Fatoração de Fisher-Neyman

> ⚙️ **Critério de Fatoração de Fisher-Neyman**
>
> Uma estatística $T(X)$ é dita **suficiente** para o parâmetro θ se e somente se a densidade conjunta $p(x \mid \theta)$ puder ser decomposta no produto de duas funções:
>
> $$p(x \mid \theta) = g(T(x), \theta) \cdot h(x)$$
>
> onde $h(x)$ depende unicamente dos dados amostrais (livre de θ) e $g(T(x), \theta)$ depende de x apenas através da estatística $T(x)$.

No prisma bayesiano, a suficiência é imediata: se $T(x)$ é suficiente, o núcleo da verossimilhança é inteiramente capturado por $g(T(x), \theta)$, o que implica que $p(\theta \mid x) = p(\theta \mid T(x))$. Ou seja, conhecer $T(x)$ basta para atingir o estado de conhecimento a posteriori perfeito sobre θ.

1.3 Catálogo Estruturado de Modelos Discretos

Apresentamos a seguir os principais modelos de probabilidade discretos, com suas parametrizações formais, intuição prática e papel na inferência bayesiana.

1. Distribuição de Bernoulli

DISCRETA

PARÂMETROS

$\theta \in [0, 1]$ (probabilidade de sucesso)

SUPORTE

$x \in \{0, 1\}$

MOMENTOS

$E[X] = \theta$, $\mathrm{Var}(X) = \theta(1-\theta)$

FUNÇÃO DE PROBABILIDADE (F.P.)

$$p(x \mid \theta) = \theta^x (1-\theta)^{1-x}$$

Quando usar: Modelagem de um único ensaio com resultado binário (sucesso/fracasso, doente/sadio, sim/não).

Papel Bayesiano: É o bloco atômico da verossimilhança para ensaios binários. Seu conjugado natural para θ é a distribuição Beta.

2. Distribuição Binomial

DISCRETA

PARÂMETROS

$n \in \mathbb{N}$ (fixado), $\theta \in [0, 1]$

SUPORTE

$x \in \{0, 1, \ldots, n\}$

MOMENTOS

$E[X] = n\theta$, $\mathrm{Var}(X) = n\theta(1-\theta)$

FUNÇÃO DE PROBABILIDADE (F.P.)

$$p(x \mid \theta) = \binom{n}{x} \theta^x (1-\theta)^{n-x}$$

Quando usar: Contagem do total de sucessos em n ensaios de Bernoulli independentes com probabilidade constante θ.

Papel Bayesiano: Forma o par conjugado clássico **Beta-Binomial**. A estatística suficiente para uma amostra de Bernoullis é a soma $T(x) = \sum x_i \sim \text{Binomial}(n, \theta)$.

3. Distribuição de Poisson

DISCRETA

PARÂMETROS

$\lambda > 0$ (taxa média de ocorrência)

SUPORTE

$x \in \{0, 1, 2, \ldots\}$

MOMENTOS

$E[X] = \lambda$, $\text{Var}(X) = \lambda$ (equidispersão)

FUNÇÃO DE PROBABILIDADE (F.P.)

$$p(x \mid \lambda) = \frac{e^{-\lambda}\lambda^{x}}{x!}$$

Quando usar: Contagem de eventos raros que ocorrem em um intervalo contínuo de tempo ou espaço sob taxa constante.

Papel Bayesiano: Forma o par conjugado **Gama-Poisson**. A estatística suficiente para uma amostra $x_1, \ldots, x_n$ é $T(x) = \sum_{i=1}^{n} x_i$.

4. Distribuição Geométrica

DISCRETA

PARÂMETROS

$\theta \in (0, 1]$ (probabilidade de sucesso)

SUPORTE

$x \in \{0, 1, 2, \ldots\}$ (fracassos até o 1º sucesso)

MOMENTOS

$E[X] = \frac{1-\theta}{\theta}$, $\text{Var}(X) = \frac{1-\theta}{\theta^2}$

FUNÇÃO DE PROBABILIDADE (F.P.)

$$p(x \mid \theta) = \theta(1-\theta)^x$$

Quando usar: Modelagem do tempo de espera até o primeiro sucesso em ensaios de Bernoulli independentes. Possui a propriedade discreta de perda de memória.

Papel Bayesiano: Como a verossimilhança é proporcional a $\theta^n(1-\theta)^{\sum x_i}$, a priori conjugada para θ também é a distribuição Beta.

5. Distribuição Binomial Negativa (Pascal)

DISCRETA

PARÂMETROS

$r > 0$ (sucessos almejados), $\theta \in (0, 1]$

SUPORTE

$x \in \{0, 1, 2, \ldots\}$ (fracassos até obter r sucessos)

MOMENTOS

$E[X] = \frac{r(1-\theta)}{\theta}$, $\text{Var}(X) = \frac{r(1-\theta)}{\theta^2} > E[X]$

FUNÇÃO DE PROBABILIDADE (F.P.)

$$p(x \mid \theta) = \binom{x+r-1}{x} \theta^r (1-\theta)^x$$

Quando usar: Generalização da Geométrica para r sucessos, ou para modelar contagens com *superdispersão* (onde a variância excede a média, violando a Poisson).

Papel Bayesiano: Surge naturalmente como a **distribuição preditiva** do modelo conjugado Gama-Poisson.

6. Distribuição Hipergeométrica

DISCRETA

PARÂMETROS

N (população), K (sucessos na pop.), n (amostra)

SUPORTE

$x \in \{\max(0, n-(N-K)), \dots, \min(n, K)\}$

MOMENTOS

$E[X] = n\frac{K}{N}$, $\text{Var}(X) = n\frac{K}{N}\left(1-\frac{K}{N}\right)\left(\frac{N-n}{N-1}\right)$

FUNÇÃO DE PROBABILIDADE (F.P.)

$$p(x) = \frac{\binom{K}{x}\binom{N-K}{n-x}}{\binom{N}{n}}$$

Quando usar: Amostragem **sem reposição** em populações finitas. O termo $\frac{N-n}{N-1}$ atua como o fator de correção de população finita.

Papel Bayesiano: Utilizada na estimação de tamanhos populacionais desconhecidos N (problema de captura-recaptura) ou de itens defeituosos K.

7. Distribuição Multinomial

DISCRETA

PARÂMETROS

n (ensaios), $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_k)$ com $\sum \theta_j = 1$

SUPORTE

$\mathbf{x} = (x_1, \ldots, x_k) \in \mathbb{N}^k$ com $\sum x_j = n$

MOMENTOS

$E[X_j] = n\theta_j$, $\mathrm{Var}(X_j) = n\theta_j(1-\theta_j)$

FUNÇÃO DE PROBABILIDADE (F.P.)

$$p(\mathbf{x} \mid \boldsymbol{\theta}) = \frac{n!}{x_1! \ldots x_k!} \prod_{j=1}^{k} \theta_j^{x_j}$$

Quando usar: Generalização da Binomial para ensaios independentes com mais de dois desfechos possíveis mutuamente exclusivos (dados categóricos multivariados).

Papel Bayesiano: Forma o par conjugado multivariado canônico **Dirichlet-Multinomial**.

1.4 Catálogo Estruturado de Modelos Contínuos

Abaixo detalhamos as principais famílias contínuas que atuam tanto como modelos amostrais quanto como prioris conjugadas fundamentais.

1. Distribuição Uniforme Contínua

CONTÍNUA

PARÂMETROS

$a, b \in \mathbb{R}$ com $a < b$

SUPORTE

$x \in [a, b]$

MOMENTOS

$E[X] = \frac{a+b}{2}$, $\mathrm{Var}(X) = \frac{(b-a)^2}{12}$

FUNÇÃO DENSIDADE DE PROBABILIDADE (F.D.P.)

$$f(x) = \frac{1}{b-a}$$

Quando usar: Quando uma variável contínua está estritamente restrita a um intervalo finito e não há nenhuma preferência por qualquer sub-região.

Papel Bayesiano: Base da clássica *priori uniforme de Bayes-Laplace* para parâmetros limitados (ex: $\theta \sim U(0, 1)$).

2. Distribuição Exponencial

CONTÍNUA

PARÂMETROS

$\lambda > 0$ (taxa)

SUPORTE

$x \in [0, \infty)$

MOMENTOS

$E[X] = \frac{1}{\lambda}$, $\mathrm{Var}(X) = \frac{1}{\lambda^2}$

FUNÇÃO DENSIDADE DE PROBABILIDADE (F.D.P.)

$$f(x \mid \lambda) = \lambda e^{-\lambda x}$$

Quando usar: Modelagem de intervalos de tempo contínuos entre ocorrências de eventos de Poisson. Possui a propriedade única de *perda de memória contínua*: $P(X > s + t \mid X > s) = P(X > t)$.

Papel Bayesiano: Caso particular de $\text{Gama}(1, \lambda)$. Sua priori conjugada para o parâmetro de taxa λ é a distribuição Gama.

3. Distribuição Gama

CONTÍNUA

PARÂMETROS

$\alpha > 0$ (forma), $\beta > 0$ (taxa)

SUPORTE

$x \in (0, \infty)$

MOMENTOS

$E[X] = \frac{alpha}{\beta}$, $\text{Var}(X) = \frac{\alpha}{\beta^2}$

FUNÇÃO DENSIDADE DE PROBABILIDADE (F.D.P.)

$$f(x \mid \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$$

Quando usar: Variáveis positivas contínuas com assimetria à direita (tempos de sobrevivência, custos, precipitação pluviométrica).

Papel Bayesiano: Peça-chave da inferência bayesiana! Atua como a **priori conjugada padrão para parâmetros de taxa da Poisson** e para a **precisão $\phi = 1/\sigma^2$ da distribuição Normal.**

4. Distribuição Qui-Quadrado (χ^2)

CONTÍNUA

PARÂMETROS

$\nu > 0$ (graus de liberdade)

SUPORTE

$x \in (0, \infty)$

MOMENTOS

$E[X] = \nu$, $\text{Var}(X) = 2\nu$

FUNÇÃO DENSIDADE DE PROBABILIDADE (F.D.P.)

$$f(x) = \frac{1}{2^{\nu/2}\Gamma(\nu/2)} x^{(\nu/2)-1} e^{-x/2}$$

Quando usar: Soma dos quadrados de ν variáveis normais padrão independentes ($X = \sum_{i=1}^{\nu} Z_i^2$).

Papel Bayesiano: É o caso especial $\text{Gama}(\alpha = \nu/2, \beta = 1/2)$, fundamental nas distribuições a posteriori de variâncias sob prioris não informativas.

5. Distribuição Beta

CONTÍNUA

PARÂMETROS

$\alpha > 0, \beta > 0$ (hiperparâmetros de forma)

SUPORTE

$\theta \in (0, 1)$

MOMENTOS

$E[\theta] = \frac{\alpha}{\alpha+\beta}$, $\text{Var}(\theta) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$

FUNÇÃO DENSIDADE DE PROBABILIDADE (F.D.P.)

$$f(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1}(1-\theta)^{\beta-1}$$

Quando usar: Modelagem flexível de probabilidades, proporções ou taxas contidas no intervalo $(0, 1)$. Dependendo de α e β, adquire forma de U, uniforme, sino simétrico ou assimétrico.

Papel Bayesiano: A **priori conjugada canônica para probabilidades de sucesso** em modelos Bernoulli e Binomial.

6. Distribuição Normal (Gaussiana) Univariada

CONTÍNUA

PARÂMETROS

$\mu \in \mathbb{R}$ (média), $\sigma^2 > 0$ ou $\tau = 1/\sigma^2$ (precisão)

SUPORTE

$x \in (-\infty, \infty)$

MOMENTOS

$E[X] = \mu$, $\text{Var}(X) = \sigma^2 = \tau^{-1}$

FUNÇÃO DENSIDADE DE PROBABILIDADE (F.D.P.)

$$f(x \mid \mu, \tau) = \sqrt{\frac{\tau}{2\pi}} \exp\left\{-\frac{\tau}{2}(x-\mu)^2\right\}$$

Quando usar: Fenômenos biológicos, físicos e erros de medição resultantes da soma de múltiplos efeitos infinitesimais (Teorema Central do Limite).

Papel Bayesiano: Conjugada com relação à média quando a variância é conhecida. A parametrização por precisão τ simplifica enormemente a álgebra bayesiana.

7. Distribuição Normal Multivariada

CONTÍNUA

PARÂMETROS

$\boldsymbol{\mu} \in \mathbb{R}^p$ (média), $\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$ (covariância)

SUPORTE

$\mathbf{x} \in \mathbb{R}^p$

MOMENTOS

$E[\mathbf{X}] = \boldsymbol{\mu}$, $\text{Cov}(\mathbf{X}) = \boldsymbol{\Sigma}$

FUNÇÃO DENSIDADE DE PROBABILIDADE (F.D.P.)

$$f(\mathbf{x}) = (2\pi)^{-p/2} |\boldsymbol{\Sigma}|^{-1/2} \exp\left\{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})\right\}$$

Quando usar: Modelagem conjunta de vetores correlacionados contínuos.

Papel Bayesiano: Base teórica da regressão linear múltipla bayesiana e processos gaussianos. Atua como priori conjugada para os coeficientes de regressão $\boldsymbol{\beta}$.

8. Distribuição t de Student

CONTÍNUA

PARÂMETROS

$\nu > 0$ (graus de lib.), $\mu \in \mathbb{R}$ (locação), $\sigma^2 > 0$ (escala)

SUPORTE

$x \in (-\infty, \infty)$

MOMENTOS

$E[X] = \mu$ (se $\nu > 1$), $\text{Var}(X) = \sigma^2 \frac{\nu}{\nu-2}$ (se $\nu > 2$)

FUNÇÃO DENSIDADE DE PROBABILIDADE (F.D.P.)

$$f(x) = \frac{\Gamma((\nu+1)/2)}{\Gamma(\nu/2)\sqrt{\pi\nu}\sigma}\left[1 + \frac{1}{\nu}\left(\frac{x-\mu}{\sigma}\right)^2\right]^{-(\nu+1)/2}$$

Quando usar: Amostras pequenas de populações normais com variância desconhecida, ou quando se deseja modelagem robusta a valores discrepantes (*outliers*) devido às caudas pesadas.

Papel Bayesiano: Surge analiticamente como a **distribuição a posteriori marginal da média** μ quando a variância σ^2 é integrada (marginalizada) a partir da Normal-Gama.

9. Distribuição Dirichlet

CONTÍNUA

PARÂMETROS

$\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_k)$ com $\alpha_j > 0$; $\alpha_0 = \sum \alpha_j$

SUPORTE

$\boldsymbol{\theta} \in \Delta_k = \{\boldsymbol{\theta} \in (0,1)^k : \sum_{j=1}^{k} \theta_j = 1\}$

MOMENTOS

$E[\theta_j] = \frac{\alpha_j}{\alpha_0}$, $\mathrm{Var}(\theta_j) = \frac{\alpha_j(\alpha_0 - \alpha_j)}{\alpha_0^2(\alpha_0+1)}$

FUNÇÃO DENSIDADE DE PROBABILIDADE (F.D.P.)

$$f(\boldsymbol{\theta}) = \frac{\Gamma(\alpha_0)}{\prod_{j=1}^{k}\Gamma(\alpha_j)} \prod_{j=1}^{k} \theta_j^{\alpha_j - 1}$$

Quando usar: É a generalização multivariada da Beta. Modela vetores de probabilidades categóricas que somam exatamente 1 (ex: proporções de votos entre k candidatos).

Papel Bayesiano: Priori conjugada para a distribuição Multinomial e base dos processos não-paramétricos de Dirichlet.

Módulo 2 Distribuições a Priori, a Posteriori e Preditivas

> 💡 **Sinopse Conceitual**
>
> O coração operacional da inferência bayesiana é o processo contínuo de aprendizado via atualização de evidências. A distribuição a priori $p(\theta)$ sintetiza nosso conhecimento ou incerteza inicial antes de olhar para a amostra. Uma vez observados os dados x, a função de verossimilhança $l(\theta; x) = p(x \mid \theta)$ atua como um operador multiplicativo de transmissão de informação. Por meio do Teorema de Bayes, combinamos ambas as fontes na distribuição a posteriori $p(\theta \mid x)$. Quando não dispomos de opiniões sólidas a priori, recorremos à teoria das prioris objetivas de Harold Jeffreys, que garante coerência matemática independentemente da escala de parametrização adotada.

2.1 O Teorema de Bayes e a Mecânica do Aprendizado

A expressão matemática da atualização bayesiana decorre diretamente da definição axiomática de probabilidade condicional de Kolmogorov. Para um espaço contínuo de parâmetros Θ e dados x:

> 📘 **Teorema de Bayes (Formulação Contínua)**
>
> $$p(\theta \mid x) = \frac{p(x, \theta)}{p(x)} = \frac{p(x \mid \theta)\, p(\theta)}{\int_{\Theta} p(x \mid \theta)\, p(\theta)\, d\theta}$$

Esta equação divide-se em quatro pilares estruturais:

1. **Distribuição a Priori** $p(\theta)$**:** Representa a incerteza probabilística sobre o vetor de parâmetros θ antes da observação da amostra atual.

2. **Verossimilhança $l(\theta; x) = p(x \mid \theta)$:** A probabilidade/densidade com que o modelo proposto geraria os dados observados x para cada valor possível de θ.

3. **Constante Normalizadora (Evidência Marginal dos Dados) $p(x)$:**

$$p(x) = \int_{\Theta} p(x \mid \theta)\, p(\theta)\, d\theta = E_{\theta}[p(x \mid \theta)]$$

   Trata-se de uma média ponderada da verossimilhança ponderada pela distribuição a priori. Ela não depende de θ, atuando estritamente como um fator de escala para assegurar que a integral da posteriori sobre todo o espaço Θ seja unitária: $\int_{\Theta} p(\theta \mid x) d\theta = 1$.

4. **Distribuição a Posteriori $p(\theta \mid x)$:** A distribuição de probabilidade atualizada sobre θ, condicionada aos dados efetivamente observados. Resume todo o conhecimento disponível após o experimento.

A Forma Proporcional

Como a evidência $p(x)$ é uma constante fixada após a coleta dos dados e não envolve o parâmetro θ, a relação bayesiana é frequentemente expressa na forma proporcional:

$$p(\theta \mid x) \propto p(x \mid \theta)\, p(\theta) \quad \Longleftrightarrow \quad \text{Posteriori} \propto \text{Verossimilhança} \times \text{Priori}$$

Em muitas deduções analíticas, basta trabalhar com o *núcleo* da posteriori (a expressão funcional em termos de θ, descartando fatores puramente multiplicativos em x) e reconhecer a qual família de distribuição conhecida esse núcleo pertence para deduzir sua constante normalizadora sem necessidade de resolver integrais complexas.

Atualização Sequencial do Conhecimento

Uma das propriedades mais elegantes do método bayesiano é que ele é um **mecanismo natural de aprendizado iterativo**: o que hoje é nossa posteriori torna-se automaticamente a priori para a próxima coleta de dados.

🔍 **Demonstração Matemática: Coerência da Atualização Sequencial**

2.2 Distribuições Preditivas

Na ciência empírica, parâmetros θ costumam ser constructos teóricos inobserváveis (uma taxa de falha intrínseca, a média populacional de glicose, a probabilidade subjacente de chuva). O que nós efetivamente observamos no mundo real são **novas realizações amostrais** Y. A inferência bayesiana trata previsões integrando sobre a incerteza do parâmetro.

1. Distribuição Preditiva a Priori

A **distribuição preditiva a priori** $p(x)$ descreve que tipo de dados devemos esperar observar antes de coletar qualquer amostra, considerando apenas o conhecimento inicial modelado na priori:

$$p(x) = \int_{\Theta} p(x \mid \theta)\, p(\theta)\, d\theta = E_{\theta}[p(X \mid \theta)]$$

Ela coincide exatamente com a constante normalizadora do Teorema de Bayes e é amplamente utilizada na *checagem preditiva a priori* (para checar se as crenças iniciais geram dados fisicamente razoáveis) e no cálculo de evidências para o Fator de Bayes.

2. Distribuição Preditiva a Posteriori

Considere agora que já observamos os dados x e desejamos prever uma nova observação futura Y. Sob a premissa de **independência condicional** (isto é, conhecendo o parâmetro verdadeiro θ, os dados futuros Y são independentes dos dados passados X, ou seja, $Y \perp X \mid \theta$), a **distribuição preditiva a posteriori** $p(y \mid x)$ é obtida integrando a densidade do novo dado ponderada pela posteriori de θ:

> 📘 **Distribuição Preditiva a Posteriori**
>
> $$p(y \mid x) = \int_{\Theta} p(y, \theta \mid x)\, d\theta = \int_{\Theta} p(y \mid \theta, x)\, p(\theta \mid x)\, d\theta = \int_{\Theta} p(y \mid \theta)\, p(\theta \mid x)\, d\theta$$
>
> $$p(y \mid x) = E_{\theta \mid x}[p(Y \mid \theta)]$$

Esta fórmula possui um significado estatístico profundo: a previsão bayesiana para Y **não é calculada simplesmente plugando um estimador pontual** $\hat{\theta}$ em $p(y \mid \hat{\theta})$ (o que subestimaria drasticamente a incerteza do sistema). Ela propaga adequadamente tanto a variabilidade aleatória inerente do processo gerador $p(y \mid \theta)$ quanto a incerteza epistêmica remanescente sobre o parâmetro $p(\theta \mid x)$.

2.3 Classificação e Estrutura das Prioris

1. Prioris Próprias versus Impróprias

- **Priori Própria:** É uma função densidade de probabilidade legítima, cuja integral sobre todo o suporte Θ converge rigorosamente para 1:

$$\int_{\Theta} p(\theta)\, d\theta = 1$$

- **Priori Imprópria:** Uma função não negativa cuja integral sobre o suporte diverge ($+\infty$):

$$\int_{\Theta} p(\theta)\, d\theta = \infty$$

  Exemplo: $p(\theta) = c > 0$ para todo $\theta \in (-\infty, \infty)$.

> ⚠️ **Cuidado Obrigatório com Prioris Impróprias**
>
> O uso de uma priori imprópria $p(\theta)$ **só é estatisticamente aceitável** se a integral da verossimilhança combinada for finita, isto é:
>
> $$p(x) = \int_{\Theta} p(x \mid \theta)\, p(\theta)\, d\theta < \infty$$
>
> Se essa integral convergir, a posteriori resultante $p(\theta \mid x) = \frac{p(x|\theta)p(\theta)}{p(x)}$ será uma **distribuição de probabilidade própria e válida.** Se divergir, a inferência será completamente inválida e colapsará.

2. Grau de Informatividade: Informativas, Vagas e Objetivas

- **Prioris Informativas:** Expressam conhecimento substancial prévio sobre θ, seja advindo de estudos clínicos anteriores, literatura consolidada ou elicitação de especialistas. Possuem variância pequena e hiperparâmetros firmemente ancorados.

- **Prioris Moderadamente Informativas (ou Regularizadoras):** Concentram massa de probabilidade em ordens de grandeza fisicamente plausíveis, evitando que o modelo explore valores absurdos, mas sem dominar a influência dos dados reais.
- **Prioris Não Informativas (Vagas / de Referência):** Têm o propósito de permitir que a evidência amostral domine completamente a inferência ("deixar os dados falarem por si mesmos"). Possuem grande dispersão (ex: $N(0, 10^4)$).

A Priori Uniforme de Bayes-Laplace e o Problema da Reparametrização

A primeira tentativa intuitiva de expressar completa ignorância sobre um parâmetro contínuo θ foi proposta por Thomas Bayes e Pierre-Simon Laplace através do *Princípio da Razão Insuficiente*: se não há motivo para favorecer nenhum valor, atribui-se densidade constante uniforme:

$$p(\theta) \propto c$$

Embora pareça uma escolha neutra, ela sofre de um grave calcanhar de Aquiles: a **falta de invariância sob transformações monótonas**. Se um pesquisador modela a probabilidade de cara $\theta \sim U(0, 1)$, um segundo pesquisador interessado nas *odds* $\phi = \frac{\theta}{1-\theta}$ (ou no logit) descobrirá, aplicando o teorema de transformação de variáveis, que sua priori implícita para ϕ é:

$$p(\phi) = p(\theta(\phi)) \left| \frac{d\theta}{d\phi} \right| = 1 \cdot \frac{1}{(1+\phi)^2}$$

Isto é, o segundo pesquisador não está mais atribuindo uma priori uniforme a ϕ, mas sim uma distribuição estritamente enviesada em direção a valores pequenos. A "ignorância" não se preservou na mudança de coordenadas!

2.4 A Priori Não Informativa de Jeffreys

Para solucionar de forma definitiva o problema da dependência de parametrização, o geofísico e estatístico britânico **Sir Harold Jeffreys** (1961) formulou uma regra objetiva fundamentada na geometria da informação da verossimilhança.

📘 A Priori de Jeffreys

Seja $I(\theta)$ a **Informação de Fisher esperada** para o parâmetro escalar θ, definida por:

$$I(\theta) = -E_{X|\theta}\left[\frac{\partial^2 \log p(X \mid \theta)}{\partial \theta^2}\right] = E_{X|\theta}\left[\left(\frac{\partial \log p(X \mid \theta)}{\partial \theta}\right)^2\right]$$

A **distribuição a priori de Jeffreys** para θ é definida como sendo proporcional à raiz quadrada da Informação de Fisher:

$$p(\theta) \propto \sqrt{I(\theta)}$$

No caso de um vetor de parâmetros $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_p)'$, a priori é proporcional à raiz quadrada do determinante da Matriz de Informação de Fisher:

$$p(\boldsymbol{\theta}) \propto \sqrt{\det \mathbf{I}(\boldsymbol{\theta})}$$

🔍 Demonstração Matemática: Invariância de Jeffreys sob Reparametrização 1-a-1

Exemplos Canônicos da Priori de Jeffreys

1. **Parâmetro de Locação:** Seja $p(x \mid \theta) = f(x - \theta)$. Como a densidade depende de x e θ apenas através da diferença, a derivada segunda de $\log f(x - \theta)$ não depende de θ. Logo, $I(\theta) = c$ (constante), resultando em:

$$p(\theta) \propto 1 \quad \text{(Uniforme imprópria na reta real)}$$

2. **Parâmetro de Escala:** Seja $p(x \mid \sigma) = \frac{1}{\sigma} f\left(\frac{x}{\sigma}\right)$. É fácil demonstrar que a informação de Fisher decresce quadraticamente com a dispersão: $I(\sigma) \propto \frac{1}{\sigma^2}$. Aplicando a raiz quadrada:

$$p(\sigma) \propto \sqrt{\frac{1}{\sigma^2}} = \frac{1}{\sigma} \quad \Longleftrightarrow \quad p(\log \sigma) \propto 1$$

3. **Modelo Bernoulli / Binomial:** Para $p(x \mid \theta) = \theta^x (1-\theta)^{1-x}$, temos:

$$\log p(x \mid \theta) = x \log \theta + (1-x) \log(1-\theta) \implies \frac{\partial^2 \log p}{\partial \theta^2} = -\frac{x}{\theta^2} - \frac{1-x}{(1-\theta)^2}$$

Como $E[X] = \theta$, aplicando a esperança negativa:

$$I(\theta) = \frac{\theta}{\theta^2} + \frac{1-\theta}{(1-\theta)^2} = \frac{1}{\theta(1-\theta)}$$

Portanto, a priori de Jeffreys é:

$$p(\theta) \propto [\theta(1-\theta)]^{-1/2} = \theta^{-1/2}(1-\theta)^{-1/2} \equiv \text{Beta}\left(\frac{1}{2}, \frac{1}{2}\right)$$

4. **Modelo de Poisson:** Para $p(x \mid \lambda) = \frac{e^{-\lambda}\lambda^x}{x!}$, a informação de Fisher é $I(\lambda) = \frac{1}{\lambda}$. Logo:

$$p(\lambda) \propto \lambda^{-1/2}$$

💡 **Priori de Jeffreys Independente para o Modelo Normal**

Se aplicarmos a regra multivariada direta de Jeffreys para a Normal com (μ, σ^2) simultaneamente desconhecidos, obtém-se $p(\mu, \sigma^2) \propto \sigma^{-3}$, o que pode causar inconsistências em certas dimensões. Harold Jeffreys propôs aplicar a regra separadamente para locação e escala ($p(\mu) \propto 1$ e $p(\sigma^2) \propto 1/\sigma^2$), assumindo independência a priori:

$$p(\mu, \sigma^2) \propto \frac{1}{\sigma^2} \quad \Longleftrightarrow \quad p(\mu, \phi) \propto \frac{1}{\phi}$$

Esta é a **priori de referência padrão** para o modelo normal, que conduz exatamente às clássicas distribuições t de Student a posteriori.

2.5 Estruturas Avançadas de Priori

1. Prioris Hierárquicas

Muitas vezes, a atribuição de valores numéricos rígidos aos hiperparâmetros de uma priori parece arbitrária. A modelagem hierárquica resolve esse dilema introduzindo múltiplos estágios de incerteza:

$$y_i \mid \theta_i \sim p(y_i \mid \theta_i) \quad \text{(Estágio 1: Modelo Amostral dos Grupos)}$$

$$\theta_i \mid \boldsymbol{\phi} \sim p(\theta_i \mid \boldsymbol{\phi}) \quad \text{(Estágio 2: Priori Populacional)}$$

$$\boldsymbol{\phi} \sim p(\boldsymbol{\phi}) \quad \text{(Estágio 3: Hiperpriori sobre os Hiperparâmetros)}$$

Essa arquitetura gera o fenômeno bayesiano fundamental conhecido como **encolhimento (*shrinkage*)** e **empréstimo de força estatística (*borrowing strength*)**: grupos com poucas observações têm suas estimativas "puxadas" em direção à média global da população, enquanto grupos com muitos dados mantêm suas estimativas fiéis aos dados locais.

2. Misturas de Prioris

Quando a incerteza inicial é multimodal (por exemplo, quando dois especialistas discordam radicalmente sobre a taxa de sucesso de uma droga), uma única distribuição unimodal é inadequada. Define-se então uma **mistura finita de prioris**:

$$p(\theta) = \sum_{k=1}^{K} w_k \, p_k(\theta), \quad \text{com } w_k > 0 \text{ e } \sum_{k=1}^{K} w_k = 1$$

Ao observar os dados x, a distribuição a posteriori também é uma mistura das posteriores individuais geradas por cada componente:

$$p(\theta \mid x) = \sum_{k=1}^{K} w_k^{*} \, p_k(\theta \mid x)$$

onde os novos pesos atualizados w_k^{*} são diretamente proporcionais à evidência marginal que cada componente forneceu para os dados observados: $w_k^{*} \propto w_k \, p_k(x)$. Assim, o próprio Teorema de Bayes se encarrega de selecionar e amplificar os especialistas cujas crenças foram mais compatíveis com a realidade observada!

Módulo 3 Famílias Conjugadas e a Família Exponencial

💡 **Sinopse Conceitual**

Em inferência bayesiana, a constante normalizadora no denominador do Teorema de Bayes pode ser analiticamente intratável para modelos genéricos.

No entanto, quando a distribuição a priori possui a mesma estrutura algébrica do núcleo da verossimilhança, a posteriori resultante pertence rigorosamente à mesma família funcional da priori.

Essa propriedade é denominada **fechamento por amostragem** ou **conjugação**.

Na Família Exponencial, a conjugação surge de forma canônica e elegante. Toda a inferência é reduzida a uma simples atualização de hiperparâmetros — onde o conhecimento a priori atua intuitivamente como *amostras virtuais adicionais*.

3.1 Definição Formal de Conjugação e Fechamento

📘 **Família de Distribuições Conjugada**

Seja $\mathcal{P} = \{p(\theta \mid \boldsymbol{\eta}) : \boldsymbol{\eta} \in H\}$ uma família de distribuições de probabilidade indexada pelo vetor de hiperparâmetros $\boldsymbol{\eta}$. Dizemos que $\mathcal{P}$ é **conjugada** para um modelo amostral $p(x \mid \theta)$ se, para qualquer priori $p(\theta) \in \mathcal{P}$ e qualquer amostra observada x, a distribuição a posteriori correspondente também pertencer a $\mathcal{P}$:

$$p(\theta) \in \mathcal{P} \implies p(\theta \mid x) \in \mathcal{P}$$

A conjugação proporciona três vantagens teóricas e práticas inestimáveis:

- **Tratabilidade Analítica:** Dispensa métodos numéricos de integração para encontrar momentos, quantis e intervalos de credibilidade.
- **Interpretação Clara dos Hiperparâmetros:** Os hiperparâmetros da priori podem ser interpretados intuitivamente como o tamanho de uma *amostra histórica* ou *pseudodados* acumulados no passado.
- **Média a Posteriori como Combinação Convexa:** Em praticamente todos os pares conjugados, a média a posteriori pode ser expressa como uma média ponderada entre a média a priori e a média dos dados observados:

$$\hat{\theta}_{\text{Bayes}} = w\, E[\theta]_{\text{priori}} + (1 - w)\, \hat{\theta}_{\text{amostra}}, \quad w \in [0, 1]$$

3.2 Conjugação na Família Exponencial

A existência de famílias conjugadas naturais não é um acidente algébrico; ela é uma consequência direta do **Teorema de Pitman-Koopman-Darmois**, que estabelece que apenas distribuições pertencentes à Família Exponencial possuem estatísticas suficientes de dimensão fixa independentemente do tamanho da amostra n.

> ⚙️ **A Família Exponencial Regular a 1 Parâmetro**
>
> Um modelo amostral pertence à Família Exponencial a um parâmetro se sua densidade puder ser expressa na forma:
>
> $$p(x \mid \theta) = a(x) \exp\left\{ u(x)\phi(\theta) - b(\theta) \right\}$$
>
> onde $u(x)$ é a estatística suficiente para θ, $\phi(\theta)$ é o parâmetro natural, e $b(\theta)$ é a função cumulante logarítmica.

Para uma amostra aleatória independente de tamanho n, $x = (x_1, \ldots, x_n)$, a verossimilhança conjunta assume a forma:

$$p(x \mid \theta) = \left[\prod_{i=1}^{n} a(x_i)\right] \exp\left\{\left[\sum_{i=1}^{n} u(x_i)\right] \phi(\theta) - n\, b(\theta)\right\}$$

Aproveitando a estrutura funcional exata dessa verossimilhança, constrói-se a **priori conjugada natural** com hiperparâmetros α e β:

$$p(\theta \mid \alpha, \beta) = k(\alpha, \beta) \exp\left\{\alpha\, \phi(\theta) - \beta\, b(\theta)\right\}$$

onde $k(\alpha, \beta)$ é a constante normalizadora que garante $\int p(\theta) d\theta = 1$.

> 🔍 **Demonstração Matemática: Atualização e Preditiva na Família Exponencial**

3.3 Os Grandes Pares Conjugados Canônicos

1. O Modelo Beta-Binomial

Seja $X \sim \text{Binomial}(n, \theta)$ com n conhecido e $\theta \in [0, 1]$. Adotamos uma priori conjugada $\theta \sim \text{Beta}(\alpha, \beta)$:

$$l(\theta; x) = \binom{n}{x} \theta^x (1-\theta)^{n-x}, \quad p(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}$$

Multiplicando os termos no Teorema de Bayes:

$$p(\theta \mid x) \propto \theta^x (1-\theta)^{n-x} \cdot \theta^{\alpha-1} (1-\theta)^{\beta-1} = \theta^{(\alpha+x)-1} (1-\theta)^{(\beta+n-x)-1}$$

Reconhecemos imediatamente o núcleo de uma nova distribuição Beta com parâmetros atualizados:

$$\theta \mid x \sim \text{Beta}(\alpha + x,\ \beta + n - x)$$

> 💡 **Intuição dos Pseudodados**
>
> A priori $\text{Beta}(\alpha, \beta)$ equivale a iniciar o experimento tendo observado previamente $\alpha - 1$ sucessos e $\beta - 1$ fracassos virtuais. A média a posteriori é uma média ponderada pura:
>
> $$E[\theta \mid x] = \frac{\alpha + x}{\alpha + \beta + n} = \left(\frac{\alpha + \beta}{\alpha + \beta + n}\right)\frac{\alpha}{\alpha + \beta} + \left(\frac{n}{\alpha + \beta + n}\right)\frac{x}{n}$$
>
> Quando $n \to \infty$, o peso da priori decai a zero e a média a posteriori converge assintoticamente para a proporção amostral clássica $\hat{\theta}_{\text{MV}} = x/n$.

> 🔍 **Demonstração Matemática: A Preditiva Beta-Binomial**

2. O Modelo Gama-Poisson

Sejam $x_1, \ldots, x_n$ observações independentes de uma distribuição $\text{Poisson}(\lambda)$, com $t = \sum_{i=1}^{n} x_i$. A verossimilhança conjunta é:

$$l(\lambda; x) = \left[\prod_{i=1}^{n} \frac{1}{x_i!}\right] e^{-n\lambda}\lambda^{t} \propto e^{-n\lambda}\lambda^{t}$$

A priori conjugada é uma $\text{Gama}(\alpha, \beta)$ com taxa β e forma α:

$$p(\lambda) = \frac{\beta^{\alpha}}{\Gamma(\alpha)}\lambda^{\alpha-1}e^{-\beta\lambda} \propto \lambda^{\alpha-1}e^{-\beta\lambda}$$

Multiplicando na regra de Bayes:

$$p(\lambda \mid x) \propto e^{-n\lambda}\lambda^{t} \cdot \lambda^{\alpha-1}e^{-\beta\lambda} = \lambda^{(\alpha+t)-1}e^{-(\beta+n)\lambda}$$

Concluímos diretamente que a distribuição a posteriori é:

$$\lambda \mid x \sim \text{Gama}(\alpha + \sum_{i=1}^{n} x_i,\ \beta + n)$$

🔍 **Demonstração Matemática: A Preditiva Binomial Negativa**

3. Modelo Normal com Variância Conhecida (Conjugação de Precisões)

Seja $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$ com variância σ^2 fixada e conhecida. É matematicamente mais elegante trabalhar com a **precisão dos dados** $\tau = 1/\sigma^2$. A verossimilhança em termos da média amostral $\bar{x} = \frac{1}{n}\sum x_i$ é:

$$l(\mu; x) \propto \exp\left\{-\frac{n\tau}{2}(\bar{x} - \mu)^2\right\}$$

Adotamos uma priori conjugada Normal para μ com média inicial μ_0 e precisão inicial $\tau_0 = 1/\sigma_0^2$:

$$p(\mu) \propto \exp\left\{-\frac{\tau_0}{2}(\mu - \mu_0)^2\right\}$$

Completando os quadrados no expoente da regra de Bayes:

$$p(\mu \mid x) \propto \exp\left\{-\frac{1}{2}\left[\tau_0(\mu - \mu_0)^2 + n\tau(\mu - \bar{x})^2\right]\right\}$$

Desenvolvendo e reagrupando os termos quadráticos e lineares em μ, obtém-se:

$$\mu \mid x \sim N(\mu_1,\ \tau_1^{-1})$$

onde os parâmetros a posteriori satisfazem a seguinte regra aditiva de precisões:

$$\tau_1 = \tau_0 + n\tau \quad \Longleftrightarrow \quad \frac{1}{\sigma_1^2} = \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}$$

$$\mu_1 = \frac{\tau_0\mu_0 + n\tau\bar{x}}{\tau_0 + n\tau} = w\,\mu_0 + (1 - w)\,\bar{x}, \quad \text{com } w = \frac{\tau_0}{\tau_0 + n\tau}$$

> 💡 **A Elegância da Adição de Precisões**
>
> Note como a incerteza se comporta: **as precisões simplesmente se somam.** Cada nova observação acrescenta uma quantidade de precisão igual a $\tau = 1/\sigma^2$ ao nosso estado de conhecimento. Se a priori for vaga ($au_0 \to 0$), o peso $w \to 0$, e a média a posteriori recai exatamente na média amostral $\bar{x}$.

4. Modelo Normal com Média Conhecida e Variância Desconhecida

Se μ é conhecido e a precisão $\phi = 1/\sigma^2$ é desconhecida, a verossimilhança é:

$$l(\phi; x) \propto \phi^{n/2} \exp\left\{ -\frac{\phi}{2} \sum_{i=1}^{n} (x_i - \mu)^2 \right\}$$

Esta forma algébrica coincide exatamente com a densidade $\text{Gama}(\alpha, \beta)$. Adotando uma priori $\phi \sim \text{Gama}(\alpha_0, \beta_0)$:

$$\phi \mid x \sim \text{Gama}\left(\alpha_0 + \frac{n}{2},\ \beta_0 + \frac{1}{2} \sum_{i=1}^{n} (x_i - \mu)^2 \right)$$

Se expressarmos o modelo em termos da variância $\sigma^2 = 1/\phi$, a priori conjugada correspondente é a **Inversa-Gama**.

5. Modelo Normal com Ambos Desconhecidos: A Priori Conjunta Normal-Gama

Quando nem a média μ nem a precisão $\phi = \sigma^{-2}$ são conhecidas, não podemos tratá-las como independentes a priori se quisermos conjugação estrita. A especificação conjugada padrão é a distribuição conjunta **Normal-Gama**:

$$\mu \mid \phi \sim N(\mu_0,\ (n_0 \phi)^{-1}), \quad \phi \sim \text{Gama}(\alpha_0, \beta_0)$$

onde n_0 representa o número de observações virtuais associadas à média a priori. A densidade conjunta a priori é:

$$p(\mu, \phi) = p(\mu \mid \phi) p(\phi) \propto \phi^{1/2} \exp\left\{ -\frac{n_0 \phi}{2} (\mu - \mu_0)^2 \right\} \phi^{\alpha_0 - 1} e^{-\beta_0 \phi}$$

Após observar a amostra $x_1, \ldots, x_n$ com média $\bar{x}$ e soma de quadrados dos desvios $S = \sum (x_i - \bar{x})^2$, a distribuição a posteriori conjunta continua sendo Normal-Gama:

$$\mu, \phi \mid x \sim \text{Normal-Gama}(\mu_n,\, n_n,\, \alpha_n,\, \beta_n)$$

com hiperparâmetros atualizados analiticamente por:

$$n_n = n_0 + n$$

$$\mu_n = \frac{n_0 \mu_0 + n\bar{x}}{n_n}$$

$$\alpha_n = \alpha_0 + \frac{n}{2}$$

$$\beta_n = \beta_0 + \frac{1}{2}S + \frac{n_0 n (\bar{x} - \mu_0)^2}{2n_n}$$

> ⚙️ **Marginais Analíticas: O Surgimento da t de Student**
>
> Integrando a precisão ϕ na posteriori conjunta, obtém-se a **distribuição a posteriori marginal da média μ**, que é exatamente uma distribuição t de Student:
>
> $$\mu \mid x \sim t_{2\alpha_n}\left(\mu_n,\ \frac{\beta_n}{\alpha_n n_n}\right)$$
>
> E a marginal para a precisão é simplesmente:
>
> $$\phi \mid x \sim \text{Gama}(\alpha_n, \beta_n)$$

6. O Caso de Duas Amostras e o Problema de Behrens-Fisher

Considere agora duas amostras normais independentes:

$$X_1, \ldots, X_{n_1} \sim N(\mu_1, \sigma_1^2) \quad \text{e} \quad Y_1, \ldots, Y_{n_2} \sim N(\mu_2, \sigma_2^2)$$

O interesse principal reside na diferença entre as médias $\delta = \mu_1 - \mu_2$.

- **Cenário Homocedástico ($\sigma_1^2 = \sigma_2^2 = \sigma^2$):** Adotando a priori de referência $p(\mu_1, \mu_2, \sigma^2) \propto 1/\sigma^2$, a posteriori marginal da diferença segue exatamente uma distribuição t de Student clássica com $n_1 + n_2 - 2$ graus de liberdade.
- **Cenário Heterocedástico ($\sigma_1^2 \neq \sigma_2^2$ - O Problema de Behrens-Fisher):** Na inferência clássica, a violação da igualdade de variâncias inviabiliza um teste t exato, demandando aproximações assintóticas como a correção de Welch-Satterthwaite.

Na inferência bayesiana, o problema de Behrens-Fisher é resolvido com absoluta naturalidade conceitual: as posteriores de (μ_1, σ_1^2) e (μ_2, σ_2^2) são calculadas de forma independente. A distribuição a posteriori marginal da diferença $\delta = \mu_1 - \mu_2$ é a **convolução exata de duas distribuições t de Student independentes:**

$$\mu_1 \mid x \sim t_{n_1-1}\left(\bar{x}, \frac{s_1^2}{n_1}\right), \quad \mu_2 \mid y \sim t_{n_2-1}\left(\bar{y}, \frac{s_2^2}{n_2}\right)$$

Embora essa convolução não admita uma fórmula fechada simples em funções elementares (sendo conhecida como a *distribuição de Behrens-Fisher*), amostrar diretamente dessa distribuição no computador via simulação é imediato: basta sortear N valores de $\mu_1^{(i)}$, N valores de $\mu_2^{(i)}$ e subtraí-los $\delta^{(i)} = \mu_1^{(i)} - \mu_2^{(i)}$, obtendo intervalos de credibilidade e probabilidades exatas sem qualquer aproximação ad-hoc!

7. O Modelo Dirichlet-Multinomial

Para contagens multivariadas $\mathbf{x} = (x_1, \ldots, x_k) \sim \text{Multinomial}(n, \boldsymbol{\theta})$, a verossimilhança é proporcional a $\prod_{j=1}^{k} \theta_j^{x_j}$. A priori conjugada no simplex unitário é $\boldsymbol{\theta} \sim \text{Dirichlet}(\alpha_1, \ldots, \alpha_k)$:

$$p(\boldsymbol{\theta}) \propto \prod_{j=1}^{k} \theta_j^{\alpha_j - 1}$$

Multiplicando na regra de Bayes, os expoentes se somam elemento a elemento:

$$p(\boldsymbol{\theta} \mid \mathbf{x}) \propto \prod_{j=1}^{k} \theta_j^{(\alpha_j + x_j) - 1} \implies \boldsymbol{\theta} \mid \mathbf{x} \sim \text{Dirichlet}(\alpha_1 + x_1,\, \ldots,\, \alpha_k + x_k)$$

Os hiperparâmetros α_j atuam como contagens prévias observadas para cada uma das k categorias.

Módulo 4 Teoria da Decisão, Estimação e Testes de Hipóteses

> 💡 **Sinopse Conceitual**
>
> A distribuição a posteriori $p(\theta \mid x)$ contém toda a informação probabilística existente sobre o parâmetro. No entanto, o mundo real exige ações concretas: fixar a dosagem de um fármaco, precificar um seguro ou decidir se aprovamos ou rejeitamos uma teoria científica. A **Teoria da Decisão Estatística** formaliza essa ponte entre crença e ação. Ao ponderarmos as consequências dos erros através de uma *função de perda*, derivamos de forma unificada os estimadores pontuais ótimos (média, mediana e moda). Na inferência intervalar, as regiões de Maior Densidade a Posteriori (HPD) garantem os menores intervalos possíveis com credibilidade fixada. Por fim, a comparação de teorias e hipóteses atinge sua forma mais expressiva através do **Fator de Bayes** e das razões de chances.

4.1 Fundamentos da Teoria da Decisão Estatística

Um problema formal de decisão estatística é especificado pela quádrupla $(\Theta, \Omega, \mathcal{A}, L)$:

- **Espaço de Estados da Natureza Θ:** O conjunto de todos os valores possíveis do parâmetro desconhecido θ.
- **Espaço Amostral Ω:** O conjunto de todos os dados observáveis x.
- **Espaço de Ações $\mathcal{A}$:** O conjunto de decisões ou estimativas possíveis $a \in \mathcal{A}$ que o estatístico pode adotar.
- **Função de Perda $L(\theta, a)$:** Uma função não-negativa $L : \Theta \times \mathcal{A} \to \mathbb{R}^+$ que quantifica o prejuízo ou custo incorrido ao tomar a ação a quando o verdadeiro estado da natureza é θ.

Risco Frequentista versus Risco a Posteriori

A divergência entre as escolas reflete-se na forma como a incerteza é integrada:

- **Risco Frequentista $R(\theta, \delta)$:** É a perda média calculada integrando sobre o espaço amostral Ω, mantendo o parâmetro θ congelado como uma constante hipotética:

$$R(\theta, \delta) = E_{X|\theta}[L(\theta, \delta(X))] = \int_{\Omega} L(\theta, \delta(x))\, p(x \mid \theta)\, dx$$

  Como depende de θ, não existe, em geral, uma regra de decisão que minimize $R(\theta, \delta)$ simultaneamente para todos os valores de θ.

- **Risco a Posteriori $\rho(a, x)$ (Perda Esperada a Posteriori):** É a perda média calculada integrando sobre o espaço de parâmetros Θ, **mantendo os dados observados x estritamente fixados:**

$$\rho(a, x) = E_{\theta|x}[L(\theta, a)] = \int_{\Theta} L(\theta, a)\, p(\theta \mid x)\, d\theta$$

> 📘 **Regra de Decisão de Bayes**
>
> O **Estimador de Bayes** $\hat{\delta}(x)$ é a ação $a^* \in \mathcal{A}$ que minimiza o risco a posteriori para a amostra observada:
>
> $$\hat{\delta}_{\text{Bayes}}(x) = \arg\min_{a \in \mathcal{A}} \rho(a, x) = \arg\min_{a \in \mathcal{A}} \int_{\Theta} L(\theta, a)\, p(\theta \mid x)\, d\theta$$

4.2 Dedução dos Estimadores Pontuais Canônicos

A beleza da teoria da decisão reside em demonstrar que os estimadores de tendência central clássicos (média, mediana e moda) não são escolhas arbitrárias; cada um é a **solução ótima exata** para uma geometria de penalização específica.

Função de Perda $L(\theta, a)$	Natureza da Penalização	Estimador de Bayes Ótimo $\hat{\theta}_{\text{Bayes}}$
Quadrática: $(a-\theta)^2$	Penaliza erros proporcionalmente ao quadrado da distância; erros grandes são severamente punidos.	**Média a Posteriori:** $\hat{\theta} = E[\theta \mid x]$
Linear Absoluta: $\lvert a-\theta \rvert$	Penaliza o erro linearmente; robusta a caudas pesadas e valores extremos.	**Mediana a Posteriori:** $\hat{\theta} = \text{Mediana}(\theta \mid x)$
Zero-Um (0-1): $I(\lvert a-\theta \rvert > \epsilon)$	Não penaliza pequenos desvios $\leq \epsilon$ e atribui perda máxima a qualquer erro maior.	**Moda a Posteriori (MAP / EMVG):** $\hat{\theta} = \arg\max_\theta p(\theta \mid x)$

🔍 **Demonstração Matemática: Minimização Rigorosa das 3 Funções de Perda**

4.3 Estimação por Intervalos: Regiões de Credibilidade e HPD

A abordagem bayesiana para inferência intervalar não sofre da ambiguidade contraintuitiva dos intervalos de confiança clássicos.

📘 **Intervalo de Credibilidade de** $100(1-\alpha)\%$

Dizemos que um subconjunto $C \subset \Theta$ é uma **região de credibilidade** de nível $1-\alpha$ para θ se a probabilidade a posteriori de que θ pertença a C satisfaz:

$$P(\theta \in C \mid x) = \int_C p(\theta \mid x)\, d\theta \geq 1-\alpha$$

1. Intervalos de Caudas Iguais (Equi-tailed)

Para um parâmetro unidimensional, a forma mais imediata de construir o intervalo $[\theta_L, \theta_U]$ é deixar uma probabilidade de $\alpha/2$ em cada uma das caudas:

$$P(\theta < \theta_L \mid x) = \frac{\alpha}{2} \quad \text{e} \quad P(\theta > \theta_U \mid x) = \frac{\alpha}{2}$$

Os limites são simplesmente os quantis $q_{\alpha/2}$ e $q_{1-\alpha/2}$ da posteriori. Sua principal vantagem é a **invariância sob transformações monótonas:** o intervalo para $\phi = g(\theta)$ é diretamente $[g(\theta_L), g(\theta_U)]$.

2. Região de Maior Densidade a Posteriori (HPD / MDP)

Em distribuições assimétricas ou multimodais, os intervalos de caudas iguais podem incluir pontos com densidade baixíssima e excluir pontos com densidade alta. Para solucionar isso, formulamos os intervalos **HPD (Highest Posterior Density)**.

> 📘 **Região HPD (Highest Posterior Density)**
>
> Uma região $C \subset \Theta$ é dita uma **região HPD** de credibilidade $1 - \alpha$ se:
>
> $$C = \{\theta \in \Theta : p(\theta \mid x) \geq k_\alpha\}$$
>
> onde k_α é a maior constante positiva tal que $P(\theta \in C \mid x) = 1 - \alpha$.

> 🔍 **Demonstração Matemática: Teorema do Volume Mínimo da Região HPD**

4.4 Testes de Hipóteses Bayesianos e o Fator de Bayes

Diferente da inferência clássica de Neyman-Pearson — que é assimétrica e só permite "rejeitar" ou "não rejeitar" a hipótese nula sem jamais atribuir probabilidade direta a ela —, a abordagem bayesiana trata o teste de hipóteses como uma comparação probabilística simétrica entre modelos concorrentes.

Razões de Chances (Odds) e Fator de Bayes

Considere duas hipóteses concorrentes, $H_0 : \theta \in \Theta_0$ e $H_1 : \theta \in \Theta_1$. Antes de coletar os dados, atribuímos probabilidades a priori $P(H_0)$ e $P(H_1)$. A **razão de chances a priori** (*prior odds*) é:

$$O(H_1, H_0) = \frac{P(H_1)}{P(H_0)}$$

Após observar os dados x, calculamos as probabilidades a posteriori $P(H_0 \mid x)$ e $P(H_1 \mid x)$. A **razão de chances a posteriori** (*posterior odds*) é:

$$O(H_1, H_0 \mid x) = \frac{P(H_1 \mid x)}{P(H_0 \mid x)}$$

📘 O Fator de Bayes (B_{10})

O **Fator de Bayes** $B_{10}(x)$ é a razão pela qual os dados observados alteram as chances relativas em favor de H_1 em detrimento de H_0:

$$\text{Odds a Posteriori} = \text{Fator de Bayes} \times \text{Odds a Priori} \quad \Longleftrightarrow \quad B_{10}(x) = \frac{O(H_1, H_0 \mid x)}{O(H_1, H_0)} = \frac{P(H_1 \mid x)/P(H_0 \mid x)}{P(H_1)/P(H_0)}$$

Pelo Teorema de Bayes, o Fator de Bayes coincide rigorosamente com a **razão entre as verossimilhanças marginais preditivas** dos dois modelos:

$$B_{10}(x) = \frac{p(x \mid H_1)}{p(x \mid H_0)} = \frac{\int_{\Theta_1} p(x \mid \theta)\, p(\theta \mid H_1)\, d\theta}{\int_{\Theta_0} p(x \mid \theta)\, p(\theta \mid H_0)\, d\theta}$$

Se $B_{10} > 1$, os dados fornecem suporte para H_1; se $B_{10} < 1$, os dados favorecem H_0. Note a simetria perfeita: $B_{01} = 1/B_{10}$.

Escala de Evidência de Harold Jeffreys

Para interpretar a magnitude do Fator de Bayes na prática científica, utiliza-se universalmente a escala calibrada proposta por Harold Jeffreys:

B_{10} (Razão de Evidência)	$2 \ln B_{10}$ (Escala em Decibéis)	Grau de Evidência em Favor de H_1 sobre H_0
1 a 3.2	0 a 2.3	Evidência anedótica (quase não vale a pena mencionar)
3.2 a 10	2.3 a 4.6	Evidência **substancial / moderada**
10 a 100	4.6 a 9.2	Evidência **forte**
> 100	> 9.2	Evidência **decisiva**

Síntese Conceitual: O Teste FBST (Full Bayesian Significance Test)

Quando nos deparamos com uma **hipótese nula pontual precisa** em um espaço contínuo (por exemplo, testar se a diferença de tratamentos é exatamente nula: $H_0 : \theta = 0$), o cálculo tradicional do Fator de Bayes exige atribuir uma probabilidade positiva concentrada pontual $P(\theta = 0) > 0$ (uma massa de Dirac), o que viola a continuidade natural da distribuição a priori e dá origem ao famoso *Paradoxo de Lindley-Jeffreys*.

> 💡 **O FBST e a Medida de Evidência (e -value)**
>
> Criado pelos estatísticos brasileiros **Carlos Alberto de Bragança Pereira** e **Julio Michael Stern** (1999), o **Full Bayesian Significance Test (FBST)** resolve esse impasse de forma estritamente bayesiana, sem distorcer o espaço com massas pontuais artificiais:
>
> 1. Trabalha-se com a distribuição a posteriori contínua original $p(\theta \mid x)$.
> 2. Identifica-se a máxima densidade alcançada sobre a variedade da hipótese nula: $m^* = \sup_{\theta \in \Theta_0} p(\theta \mid x)$.
> 3. Define-se o *conjunto tangencial* $T = \{\theta \in \Theta : p(\theta \mid x) > m^*\}$, que contém todos os pontos do espaço paramétrico cuja plausibilidade a posteriori é **estritamente maior** que qualquer ponto sob H_0.
> 4. A evidência contra H_0 é calculada integrando a posteriori sobre esse conjunto: $Ev(H_0) = \int_T p(\theta \mid x) d\theta$. O e-**value** em favor de H_0 é simplesmente $e^* = 1 - Ev(H_0)$.
>
> Se o e-value for muito pequeno, significa que quase toda a massa de probabilidade a posteriori reside em regiões mais plausíveis do que a hipótese nula, justificando a rejeição de H_0 sob uma interpretação geométrica pura da distribuição a posteriori.

Módulo 5 Computação Bayesiana e Métodos Estocásticos

> 💡 **Sinopse Conceitual**
>
> O Teorema de Bayes estabelece uma teoria inferencial unificada e elegante.
>
> No entanto, sua aplicação em modelos complexos e realistas enfrenta uma barreira matemática: **a constante de normalização e as distribuições marginais exigem integrais em dimensões elevadas sem solução analítica fechada.**
>
> Métodos numéricos determinísticos sucumbem rapidamente à maldição da dimensionalidade.
>
> A moderna revolução bayesiana foi impulsionada por algoritmos de simulação estocástica: *Monte Carlo Simples*, *Amostragem por Importância* e, sobretudo, **Monte Carlo via Cadeias de Markov (MCMC)** — onde simulamos trajetórias cuja distribuição de equilíbrio estacionária é exatamente a posteriori desejada.

5.1 O Desafio da Integração Numérica em Altas Dimensões

Praticamente todo objetivo na inferência bayesiana pode ser formalizado como o cálculo da esperança a posteriori de alguma função de interesse $g(\boldsymbol{\theta})$:

$$E[g(\boldsymbol{\theta}) \mid x] = \int_{\Theta} g(\boldsymbol{\theta})\, p(\boldsymbol{\theta} \mid x)\, d\boldsymbol{\theta} = \frac{\int_{\Theta} g(\boldsymbol{\theta})\, p(x \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, d\boldsymbol{\theta}}{\int_{\Theta} p(x \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, d\boldsymbol{\theta}}$$

Se o vetor $\boldsymbol{\theta}$ tem dimensão $d = 20$ e tentarmos usar uma regra de quadratura determinística simples dividindo cada eixo em apenas 10 pontos, precisaremos avaliar a verossimilhança em 10^{20} nós — o que exigiria séculos de processamento nos supercomputadores mais rápidos do planeta! É a célebre **maldição da dimensionalidade.**

5.2 Métodos de Monte Carlo sem Cadeias

1. Monte Carlo Simples

Se tivermos um algoritmo capaz de gerar amostras independentes e identicamente distribuídas (i.i.d.) $\boldsymbol{\theta}^{(1)}, \ldots, \boldsymbol{\theta}^{(N)}$ diretamente da posteriori $p(\boldsymbol{\theta} \mid x)$, a esperança teórica é aproximada pela média amostral empírica:

$$\bar{g}_N = \frac{1}{N} \sum_{i=1}^{N} g(\boldsymbol{\theta}^{(i)})$$

Pela **Lei Forte dos Grandes Números**, $\bar{g}_N \xrightarrow{\text{q.c.}} E[g(\boldsymbol{\theta}) \mid x]$ conforme $N \to \infty$. Além disso, pelo **Teorema Central do Limite**, o *Erro Padrão de Monte Carlo* decresce a uma taxa estritamente universal de ordem $O(1/\sqrt{N})$, **independentemente da dimensão d do espaço!**

$$MCSE = \frac{s_g}{\sqrt{N}}, \quad \text{onde } s_g^2 = \frac{1}{N-1} \sum_{i=1}^{N} (g(\boldsymbol{\theta}^{(i)}) - \bar{g}_N)^2$$

2. Amostragem por Importância (Importance Sampling)

Quando não é viável amostrar diretamente de $p(\theta \mid x)$, introduz-se uma **densidade instrumental ou auxiliar** $q(\theta)$ cujo suporte contenha o de $p(\theta \mid x)$ e da qual sabemos gerar amostras facilmente. Reescrevemos a integral como:

$$E[g(\theta) \mid x] = \int g(\theta) \frac{p(\theta \mid x)}{q(\theta)} q(\theta) d\theta = E_q[g(\theta) w(\theta)]$$

onde $w(\theta) = \frac{p(\theta|x)}{q(\theta)}$ é denominado **peso de importância**. Se a constante normalizadora de $p(\theta \mid x)$ for desconhecida ($p(\theta \mid x) = \frac{q^*(\theta)}{k}$), utilizamos os pesos normalizados:

$$\hat{I}_{IS} = \sum_{i=1}^{N} W_i \, g(\theta^{(i)}), \quad \text{com } W_i = \frac{w(\theta^{(i)})}{\sum_{j=1}^{N} w(\theta^{(j)})}$$

3. Métodos de Reamostragem: Rejeição e SIR

- **Método da Rejeição:** Encontra-se uma constante $M > 0$ tal que a proposta majora o núcleo: $Mq(\theta) \geq p(x \mid \theta)p(\theta)$ para todo θ. Gera-se $\theta^* \sim q(\theta)$ e $u \sim U(0,1)$; aceita-se θ^* se $u \leq \frac{p(x|\theta^*)p(\theta^*)}{Mq(\theta^*)}$. A taxa média de

aceitação é $1/M$. Em altas dimensões, M torna-se astronomicamente grande e a aceitação colapsa para zero.

- **Reamostragem Ponderada (Sampling-Importance-Resampling / SIR):** Em vez de rejeitar pontos um a um, gera-se uma amostra preliminar de tamanho M de $q(\theta)$, calculam-se os pesos normalizados W_i e, no terceiro passo, reamostram-se $N < M$ valores com probabilidades proporcionais a W_i. É a base do filtro de partículas e do bootstrap bayesiano.

5.3 Monte Carlo via Cadeias de Markov (MCMC)

Para contornar as falhas dos métodos anteriores em dimensões moderadas e altas, o MCMC constrói uma **cadeia de Markov ergódica** cujo espaço de estados é Θ e cuja **distribuição estacionária invariante** coincide exatamente com a distribuição a posteriori alvo $\pi(\theta) = p(\theta \mid x)$.

> ⚙️ **A Condição de Balanço Detalhado**
>
> Seja $T(\theta \to \theta')$ a densidade de transição de mover do estado θ para θ'. A distribuição $\pi(\theta)$ é garantidamente a distribuição estacionária da cadeia se a transição satisfizer a condição de **balanço detalhado** (reversibilidade microscópica):
>
> $$\pi(\theta)\, T(\theta \to \theta') = \pi(\theta')\, T(\theta' \to \theta) \quad \forall\, \theta, \theta' \in \Theta$$

1. O Algoritmo de Metropolis-Hastings

O algoritmo proposto por Nicholas Metropolis (1953) e generalizado por W. K. Hastings (1970) divide a transição em duas etapas: um mecanismo de **proposta** $q(\theta' \mid \theta)$ seguido de uma decisão probabilística de **aceitação** com probabilidade $\alpha(\theta, \theta')$.

📘 Algoritmo de Metropolis-Hastings

Estando no estado atual $\theta^{(t)}$ na iteração t:

1. Gere um candidato θ' a partir da distribuição proposta $q(\theta' \mid \theta^{(t)})$.

2. Calcule a **razão de aceitação de Metropolis-Hastings:**

$$\alpha(\theta^{(t)}, \theta') = \min\left(1,\ \frac{\pi(\theta')\, q(\theta^{(t)} \mid \theta')}{\pi(\theta^{(t)})\, q(\theta' \mid \theta^{(t)})}\right) = \min\left(1,\ \frac{p(x \mid \theta')\, p(\theta')\, q(\theta^{(t)} \mid \theta')}{p(x \mid \theta^{(t)})\, p(\theta^{(t)})\, q(\theta' \mid \theta^{(t)})}\right)$$

3. Gere $u \sim U(0,1)$. Se $u \leq \alpha(\theta^{(t)}, \theta')$, **aceite** e faça $\theta^{(t+1)} = \theta'$. Caso contrário, **rejeite** e repita o estado anterior: $\theta^{(t+1)} = \theta^{(t)}$.

🔍 Demonstração Matemática: O Metropolis-Hastings Satisfaz o Balanço Detalhado

2. O Amostrador de Gibbs

Proposto por Geman & Geman (1984) e introduzido na estatística por Gelfand & Smith (1990), o **Amostrador de Gibbs** é um caso particular extraordinário de Metropolis-Hastings aplicável quando o vetor de parâmetros é multidimensional $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_d)'$ e conhecemos a forma analítica das **distribuições condicionais completas (*full conditionals*):**

$$\pi(\theta_j \mid \boldsymbol{\theta}_{-j}, x) = p(\theta_j \mid \theta_1, \ldots, \theta_{j-1}, \theta_{j+1}, \ldots, \theta_d, x)$$

Em cada iteração $t+1$, atualiza-se uma coordenada por vez utilizando os valores mais recentes disponíveis:

$$\theta_1^{(t+1)} \sim \pi(\theta_1 \mid \theta_2^{(t)}, \theta_3^{(t)}, \ldots, \theta_d^{(t)}, x)$$

$$\theta_2^{(t+1)} \sim \pi(\theta_2 \mid \theta_1^{(t+1)}, \theta_3^{(t)}, \ldots, \theta_d^{(t)}, x)$$

$$\vdots$$

$$\theta_d^{(t+1)} \sim \pi(\theta_d \mid \theta_1^{(t+1)}, \theta_2^{(t+1)}, \ldots, \theta_{d-1}^{(t+1)}, x)$$

Como a distribuição proposta é exatamente a condicional completa, ao substituir na fórmula de Metropolis-Hastings verifica-se que **a probabilidade de aceitação α é identicamente igual a 100%**: todo candidato gerado no Amostrador de Gibbs é aceito automaticamente!

3. MCMC de Dimensão Variável: Reversible Jump MCMC (RJMCMC)

Em problemas de seleção e comparação de modelos concorrentes $\mathcal{M}_1, \ldots, \mathcal{M}_K$, cada modelo pode ter um número diferente de parâmetros (por exemplo, comparar uma regressão com 2 preditores contra uma com 5 preditores). Peter Green (1995) formulou o **RJMCMC** para permitir que a cadeia salte entre subespaços de dimensões desiguais.

Para saltar de um modelo de dimensão menor n_k para um maior $n_{k'}$, gera-se um vetor de variáveis auxiliares $u \sim q(u)$ com dimensão $n_{k'} - n_k$, e define-se uma bijeção determinística diferenciável $\theta' = g(\theta, u)$. A razão de aceitação incorpora o **determinante Jacobiano** da transformação para garantir a reversibilidade:

$$\alpha = \min\left(1,\ \frac{\pi(k', \theta')\, r_{k',k}}{\pi(k, \theta)\, r_{k,k'}\, q(u)} \left| \det \frac{\partial g(\theta, u)}{\partial(\theta, u)} \right| \right)$$

5.4 Laboratório Prático: Implementações em R e Python

Abaixo apresentamos snippets comparativos autocontidos para rodar e visualizar o funcionamento dos algoritmos de simulação.

Exemplo 1: Metropolis-Hastings para uma Distribuição Bimodal

=== Código em R ===

```r
# Metropolis-Hastings para Mistura Bimodal em R
set.seed(42)
target_log_density ← function(theta) {
  # Alvo: Mistura de 2 Normais 0.3*N(-3, 1) + 0.7*N(3, 1)
  log(0.3 * dnorm(theta, -3, 1) + 0.7 * dnorm(theta, 3, 1))
}
```

```
N ← 10000
chain ← numeric(N)
chain[1] ← 0  # Ponto inicial
sigma_prop ← 1.5
accepted ← 0

for (t in 1:(N - 1)) {
  current ← chain[t]
  candidate ← rnorm(1, mean = current, sd = sigma_prop)

  log_alpha ← target_log_density(candidate) - target_log_density(current)
  if (log(runif(1)) < log_alpha) {
    chain[t + 1] ← candidate
    accepted ← accepted + 1
  } else {
    chain[t + 1] ← current
  }
}

cat("Taxa de Aceitação:", round(accepted / N, 3), "\n")
par(mfrow = c(1, 2))
plot(chain[1:1000], type = "l", col = "#2563eb", main = "Traceplot (1000 iter)", ylab = expression(theta))
hist(chain[2000:N], breaks = 40, prob = TRUE, col = "#e0f2fe", border = "#0369a1", main = "Posteriori Estimada")
curve(0.3 * dnorm(x, -3, 1) + 0.7 * dnorm(x, 3, 1), add = TRUE, col = "#ea580c", lwd = 2)
```

=== Código em Python ===

```
# Metropolis-Hastings para Mistura Bimodal em Python
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(42)

def target_density(theta):
    # Alvo: 0.3*N(-3, 1) + 0.7*N(3, 1)
    p1 = 0.3 * np.exp(-0.5 * (theta + 3)**2) / np.sqrt(2 * np.pi)
    p2 = 0.7 * np.exp(-0.5 * (theta - 3)**2) / np.sqrt(2 * np.pi)
    return p1 + p2

N = 10000
chain = np.zeros(N)
sigma_prop = 1.5
accepted = 0
```

```
for t in range(N - 1):
    current = chain[t]
    candidate = np.random.normal(current, sigma_prop)

    alpha = target_density(candidate) / target_density(current)
    if np.random.uniform(0, 1) < alpha:
        chain[t + 1] = candidate
        accepted += 1
    else:
        chain[t + 1] = current

print(f"Taxa de Aceitação: {accepted / N:.3f}")

# Visualização
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(11, 4))
ax1.plot(chain[:1000], color='#2563eb', lw=0.8)
ax1.set_title("Traceplot (Primeiras 1000 iterações)")
ax2.hist(chain[2000:], bins=40, density=True, color='#bae6fd', edgecolor='#0284c7')
x = np.linspace(-7, 7, 200)
ax2.plot(x, target_density(x), color='#ea580c', lw=2, label="Densidade Exata")
ax2.set_title("Histograma da Cadeia vs Alvo Teórico")
ax2.legend()
plt.tight_layout()
plt.show()
```

Exemplo 2: Amostrador de Gibbs para Normal Bivariada

=== Código em R ===

```
# Amostrador de Gibbs para Normal Bivariada Correlacionada em R
# Alvo: (X, Y) ~ N_2(0, [1, rho; rho, 1])
# Condicionais: X|Y ~ N(rho*Y, 1 - rho^2) e Y|X ~ N(rho*X, 1 - rho^2)
set.seed(42)
rho ← 0.8
N ← 5000
cond_sd ← sqrt(1 - rho^2)

chain_x ← numeric(N)
chain_y ← numeric(N)
chain_x[1] ← -4
chain_y[1] ← 4
```

```r
for (t in 1:(N - 1)) {
  # 1. Atualizar X dado o Y mais recente
  chain_x[t + 1] ← rnorm(1, mean = rho * chain_y[t], sd = cond_sd)
  # 2. Atualizar Y dado o X recém-gerado
  chain_y[t + 1] ← rnorm(1, mean = rho * chain_x[t + 1], sd = cond_sd)
}

plot(chain_x[100:1000], chain_y[100:1000], pch = 16, cex = 0.5, col = rgb(0.1, 0.4, 0.9, 0.4),
     main = "Amostras Conjuntas de Gibbs (rho = 0.8)", xlab = expression(theta[1]), ylab = expression(theta[2]))
```

=== Código em Python ===

```python
# Amostrador de Gibbs para Normal Bivariada em Python
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(42)
rho = 0.8
N = 5000
cond_sd = np.sqrt(1 - rho**2)

x = np.zeros(N)
y = np.zeros(N)
x[0], y[0] = -4.0, 4.0

for t in range(N - 1):
    # 1. Atualiza X condicionado no Y atual
    x[t + 1] = np.random.normal(rho * y[t], cond_sd)
    # 2. Atualiza Y condicionado no X atualizado
    y[t + 1] = np.random.normal(rho * x[t + 1], cond_sd)

plt.figure(figsize=(6, 6))
plt.scatter(x[200:], y[200:], alpha=0.3, s=8, color='#0284c7')
plt.title(f"Amostras do Amostrador de Gibbs (ρ = {rho})")
plt.xlabel("θ₁")
plt.ylabel("θ₂")
plt.grid(True, alpha=0.3)
plt.show()
```

5.5 Diagnósticos Rigorosos de Convergência

Como o MCMC produz amostras correlacionadas geradas de forma sequencial, é mandatório realizar diagnósticos formais antes de confiar nas estimativas:

📘 1. Período de Aquecimento (Burn-in)

O ponto de partida arbitrário $\theta^{(0)}$ pode estar em uma região de probabilidade baixíssima. O **burn-in** consiste em descartar as primeiras B iterações da cadeia (comumente 10% a 50%) para assegurar que a amostragem seja coletada apenas após a cadeia ter atingido sua distribuição de equilíbrio estacionária.

📘 2. Autocorrelação, Desbaste (Thinning) e Tamanho Efetivo (ESS)

Devido à natureza da cadeia, $\theta^{(t)}$ e $\theta^{(t+k)}$ possuem autocorrelação positiva ρ_k. O **Tamanho Amostral Efetivo** (ESS) quantifica quantas observações verdadeiramente independentes a cadeia correlacionada equivale:

$$ESS = \frac{N}{1 + 2\sum_{k=1}^{\infty} \rho_k}$$

Se o ESS for muito inferior a N, recomenda-se aplicar **desbaste** (***thinning***), guardando apenas a cada k -ésima observação (ex: guardar de 5 em 5 passos) para economizar memória e reduzir a dependência serial.

⚙️ 3. Fator de Redução de Escala Potencial de Gelman-Rubin ($\hat{R}$)

O diagnóstico padrão-ouro consiste em inicializar $M \geq 3$ cadeias independentes a partir de pontos amplamente dispersos no espaço e comparar a **variância intra-cadeia** (W) com a **variância entre-cadeias** (B):

$$W = \frac{1}{M}\sum_{m=1}^{M} s_m^2, \quad \frac{B}{N} = \frac{1}{M-1}\sum_{m=1}^{M}(\bar{\theta}_m - \bar{\bar{\theta}})^2$$

A variância marginal estimada combinada é $\widehat{\mathrm{Var}}(\theta) = \frac{N-1}{N}W + \frac{1}{N}B$. O índice de Gelman-Rubin é dado por:

$$\hat{R} = \sqrt{\frac{\widehat{\mathrm{Var}}(\theta)}{W}}$$

Critério de Parada: Se $\hat{R} \approx 1.0$ (universalmente aceito se $\hat{R} < 1.05$), todas as cadeias convergiram para a mesma região estacionária e estão bem misturadas. Se $\hat{R} > 1.1$, as cadeias ainda estão explorando regiões distintas e as simulações devem ser continuadas.

Módulo 6 Modelos Lineares e ANOVA Bayesiana

> 💡 **Sinopse Conceitual**
>
> O Modelo Linear Normal constitui a viga-mestra da modelagem estatística aplicada.
>
> Na inferência bayesiana, a formulação matricial generaliza a estrutura conjugada Normal-Gama para dimensões arbitrárias com notável concisão.
>
> Sob a priori de referência de Jeffreys, os estimadores pontuais coincidem numericamente com os Mínimos Quadrados Ordinários (MQO).
>
> Contudo, a interpretação bayesiana supera as limitações frequentistas: dispomos da distribuição de probabilidade exata dos efeitos, permitindo testar **contrastes lineares em ANOVA** de forma direta, sem a necessidade de correções artificiais para testes múltiplos.

6.1 O Modelo de Regressão Linear Múltipla Normal

Considere n observações de uma variável resposta contínua y_i associadas a k variáveis explicativas $\mathbf{x}_i = (x_{i1}, \ldots, x_{ik})'$. Na notação matricial padrão:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim N_n(\mathbf{0},\ \phi^{-1}\mathbf{I}_n)$$

onde:

- $\mathbf{y} \in \mathbb{R}^{n\times 1}$ é o vetor de respostas observadas;
- $\mathbf{X} \in \mathbb{R}^{n\times k}$ é a matriz de planejamento ou delineamento (posto completo $k < n$);
- $\boldsymbol{\beta} = (\beta_1, \ldots, \beta_k)' \in \mathbb{R}^{k\times 1}$ é o vetor de coeficientes de regressão;
- $\phi = \sigma^{-2} > 0$ é a precisão dos erros aleatórios gaussianos.

A Função de Verossimilhança Matricial

Como os erros são i.i.d. normais, a verossimilhança conjunta para $(\boldsymbol{\beta}, \phi)$ é:

$$l(\boldsymbol{\beta}, \phi; \mathbf{y}) = (2\pi)^{-n/2} \phi^{n/2} \exp\left\{ -\frac{\phi}{2} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \right\}$$

Definindo o estimador clássico de Mínimos Quadrados Ordinários $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ e a soma de quadrados dos resíduos $S = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$, decompomos a forma quadrática em dois termos ortogonais:

$$(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = S + (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})'(\mathbf{X}'\mathbf{X})(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})$$

Portanto, a verossimilhança separa-se naturalmente em:

$$l(\boldsymbol{\beta}, \phi; \mathbf{y}) \propto \phi^{n/2} \exp\left\{ -\frac{\phi}{2} \left[S + (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})'(\mathbf{X}'\mathbf{X})(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) \right] \right\}$$

6.2 Análise sob Priori Não Informativa de Jeffreys

Quando não há conhecimento prévio substancial sobre os efeitos das covariáveis ou a precisão, adota-se a **priori de referência de Jeffreys** para parâmetros de locação e escala multivariados:

$$p(\boldsymbol{\beta}, \phi) \propto \frac{1}{\phi} \quad \Longleftrightarrow \quad p(\boldsymbol{\beta}, \sigma^2) \propto \frac{1}{\sigma^2}$$

⚙️ Posteriori Conjunta e Marginais sob Priori de Referência

Multiplicando a verossimilhança pela priori de Jeffreys no Teorema de Bayes, obtemos:

1. **Posteriori Condicional de $\boldsymbol{\beta}$ dada a precisão ϕ:**

$$\boldsymbol{\beta} \mid \phi, \mathbf{y} \sim N_k \left(\hat{\boldsymbol{\beta}},\ [\phi(\mathbf{X}'\mathbf{X})]^{-1} \right)$$

2. **Posteriori Marginal da Precisão ϕ:**

$$\phi \mid \mathbf{y} \sim \text{Gama}\left(\frac{n-k}{2},\ \frac{S}{2} \right) \quad \Longleftrightarrow \quad \frac{S}{\sigma^2} \mid \mathbf{y} \sim \chi^2_{n-k}$$

3. **Posteriori Marginal dos Coeficientes $\boldsymbol{\beta}$:** Integrando ϕ analiticamente, a distribuição marginal de $\boldsymbol{\beta}$ é uma t **de Student multivariada** com $n-k$ graus de liberdade:

$$\boldsymbol{\beta} \mid \mathbf{y} \sim t_{n-k} \left(\hat{\boldsymbol{\beta}},\ s^2 (\mathbf{X}'\mathbf{X})^{-1} \right)$$

   onde $s^2 = \frac{S}{n-k}$ é a variância residual amostral não viesada.

> 💡 **Equivalência Numérica vs Diferença Conceitual**
>
> Sob a priori de Jeffreys, a média a posteriori $\hat{\boldsymbol{\beta}}_{\text{Bayes}} = \hat{\boldsymbol{\beta}}$ coincide **numericamente** com a estimativa pontual de Mínimos Quadrados e com os limites dos intervalos de confiança clássicos. No entanto, o significado epistemológico é diametralmente oposto:
>
> - O estatístico frequentista precisa dizer: *"O parâmetro $\boldsymbol{\beta}$ é uma constante fixa; se repetíssemos o experimento infinitas vezes, 95% dos intervalos aleatórios conteriam esse valor."*
> - O estatístico bayesiano afirma diretamente: *"Condicionado aos dados observados, existe uma probabilidade real de 95% de que o efeito β_j esteja contido no intervalo de credibilidade calculado."*

6.3 Análise de Variância (ANOVA) com 1 Fator de Classificação

A Análise de Variância com um fator de classificação destina-se a comparar as médias de uma variável resposta contínua entre p grupos ou tratamentos independentes. Sob a ótica bayesiana, a ANOVA é expressa diretamente como um caso especial do modelo linear geral.

O Modelo em Médias de Grupos

Para a i-ésima observação no j-ésimo grupo ($j = 1, \ldots, p$ e $i = 1, \ldots, n_j$), com tamanho total $n = \sum_{j=1}^{p} n_j$:

$$y_{ij} = \beta_j + \epsilon_{ij}, \quad \epsilon_{ij} \sim N(0, \sigma^2)$$

onde β_j representa a média populacional verdadeira do j-ésimo tratamento e σ^2 é a variância comum intra-grupos (homocedasticidade).

A Estrutura da Matriz de Delineamento

A matriz de projeto $\mathbf{X} \in \mathbb{R}^{n \times p}$ é composta por colunas indicadoras em blocos:

$$\mathbf{X} = \begin{bmatrix} \mathbf{1}_{n_1} & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \mathbf{1}_{n_2} & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{1}_{n_p} \end{bmatrix}$$

A matriz de covariância cruzada $\mathbf{X}'\mathbf{X}$ resulta em uma **matriz diagonal pura** cujos elementos da diagonal principal são os respectivos tamanhos amostrais dos grupos:

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} n_1 & 0 & \cdots & 0 \\ 0 & n_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & n_p \end{bmatrix} = \operatorname{diag}(n_1, n_2, \ldots, n_p)$$

Por ser diagonal, sua inversa é trivialmente $(\mathbf{X}'\mathbf{X})^{-1} = \operatorname{diag}\left(\frac{1}{n_1}, \ldots, \frac{1}{n_p}\right)$, e o vetor de estimadores MQO é o vetor das médias amostrais observadas em cada grupo:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\bar{y}_1, \bar{y}_2, \ldots, \bar{y}_p)'$$

Distribuição a Posteriori dos Efeitos de Tratamento

Adotando a priori de referência $p(\boldsymbol{\beta}, \sigma^2) \propto 1/\sigma^2$, a distribuição a posteriori conjunta dos parâmetros condicionada à variância residual é uma Normal multivariada com matriz de covariância diagonal:

$$\beta_j \mid \sigma^2, \mathbf{y} \sim N\left(\bar{y}_j,\ \frac{\sigma^2}{n_j}\right) \quad \text{independentes entre si}$$

E a marginal para cada média de grupo é uma t de Student univariada com $n - p$ graus de liberdade:

$$\beta_j \mid \mathbf{y} \sim t_{n-p}\left(\bar{y}_j,\ \frac{s^2}{n_j}\right), \quad \text{onde } s^2 = \frac{\sum_{j=1}^{p}\sum_{i=1}^{n_j}(y_{ij} - \bar{y}_j)^2}{n - p}$$

6.4 Inferência Exata sobre Contrastes

Na prática experimental, raramente estamos interessados apenas em testar a hipótese global genérica de que "todos os grupos são iguais". O verdadeiro interesse científico quase sempre reside em **contrastes específicos** entre tratamentos.

📘 Contraste Linear

Um **contraste linear** entre as médias dos tratamentos é qualquer combinação linear $\psi = \sum_{j=1}^{p} c_j \beta_j = \mathbf{c}'\boldsymbol{\beta}$ cujos coeficientes satisfazem a restrição de soma zero:

$$\sum_{j=1}^{p} c_j = 0$$

Exemplos comuns de contrastes:

- **Comparação Simples entre dois tratamentos:** $\psi = \beta_1 - \beta_2$ (com $\mathbf{c} = (1, -1, 0, \ldots, 0)'$).
- **Controle versus Média dos Novos Tratamentos:** $\psi = \beta_1 - \frac{\beta_2 + \beta_3}{2}$ (com $\mathbf{c} = (1, -0.5, -0.5)'$).

⚙️ Distribuição Exata de um Contraste a Posteriori

Como $\boldsymbol{\beta} \mid \mathbf{y} \sim t_{n-p}(\hat{\boldsymbol{\beta}}, s^2(\mathbf{X}'\mathbf{X})^{-1})$, qualquer combinação linear $\psi = \mathbf{c}'\boldsymbol{\beta}$ tem distribuição t de Student univariada exata:

$$\psi \mid \mathbf{y} \sim t_{n-p}\left(\hat{\psi},\ s^2 \sum_{j=1}^{p} \frac{c_j^2}{n_j}\right), \quad \text{com } \hat{\psi} = \sum_{j=1}^{p} c_j \bar{y}_j$$

💡 O Fim das "Correções para Múltiplas Comparações"

Na ANOVA frequentista clássica, testar múltiplos contrastes inflaciona a taxa de erro do tipo I, forçando o pesquisador a recorrer a penalizações artificiais (como os métodos de Bonferroni, Tukey HSD ou Scheffé). Na abordagem bayesiana:

- Não existe "inflação de erro tipo I" porque não se calculam taxas de erro em infinitas repetições hipotéticas.
- A distribuição a posteriori conjunta $p(\boldsymbol{\beta} \mid \mathbf{y})$ é **uma só e já contém toda a correlação e incerteza global** do experimento.
- Podemos calcular diretamente a probabilidade de qualquer afirmação científica substantiva, como:

$$P(\beta_1 > \beta_2 \mid \mathbf{y}) = P(\beta_1 - \beta_2 > 0 \mid \mathbf{y}) = \int_0^\infty p(\psi \mid \mathbf{y})\, d\psi$$

Se essa probabilidade for, por exemplo, 0.985, concluímos imediatamente que há 98.5% de certeza de que o tratamento 1 é superior ao tratamento 2 — uma resposta transparente, intuitiva e epistemologicamente inatacável.
